

Predicción de la calidad del vino mediante técnicas de Machine Learning

EDA, validación cruzada anidada, selección de variables y curva Precision-Recall

Autor: Iván Calvo Benito

Asignatura: Técnicas Estadísticas en Minería de Datos

1. Resumen / Abstract

Resumen

En este trabajo se analiza el conjunto de datos `wine_quality.csv` con el objetivo de predecir la calidad del vino a partir de sus características fisicoquímicas. La variable respuesta es `quality`, por lo que el problema se aborda como una tarea de clasificación multiclase. El análisis exploratorio muestra que no hay valores perdidos y que la variable respuesta está claramente desbalanceada: la mayoría de los vinos se concentra en las calidades 5 y 6, mientras que las clases extremas tienen una representación muy baja. Además, variables como `alcohol`, `density`, `volatile_acidity` y `chlorides` presentan relaciones relevantes con la calidad.

Para la predicción se comparan cuatro modelos supervisados: Regresión Logística, KNN, Random Forest y SVM con kernel RBF. Todos se integran en pipelines con imputación, escalado y selección de variables mediante `SelectKBest`, evitando fuga de información. La optimización se realiza mediante validación cruzada anidada y se usa F1-macro como métrica principal debido al desbalanceo entre clases. El mejor modelo es Random Forest, con F1-macro medio de 0,2870 en la Nested CV. Para la evaluación final se emplean predicciones out-of-fold obtenidas mediante `cross_val_predict` con el pipeline configurado con la moda de hiperparámetros. En esta evaluación se obtiene un F1-macro OOF de 0,2851 y una accuracy OOF de 0,4818. El modelo final selecciona cinco variables: `volatile_acidity`, `chlorides`, `free_sulfur_dioxide`, `density` y `alcohol`. Finalmente, la curva Precision-Recall micro-promediada obtiene un Average Precision de 0,4897 y un punto óptimo con umbral 0,2511, precision 0,4343, recall 0,7362 y F1 0,5463. Como complemento, la curva ROC micro-promediada alcanza un AUC de 0,8787.

Palabras clave: calidad del vino, clasificación multiclase, validación cruzada anidada, Random Forest, selección de variables, curva Precision-Recall.

Abstract

This project analyses the `wine_quality.csv` dataset in order to predict wine quality from its physicochemical characteristics. The response variable is `quality`, so the problem is formulated as a multiclass classification task. The exploratory data analysis shows that there are no missing values and that the target variable is clearly imbalanced: most wines are concentrated in quality levels 5 and 6, while the extreme classes are poorly represented. Variables such as `alcohol`, `density`, `volatile_acidity` and `chlorides` also show relevant relationships with wine quality.

Four supervised models are compared: Logistic Regression, KNN, Random Forest and SVM with an RBF kernel. All models are implemented in pipelines including imputation, scaling and feature selection with `SelectKBest`, preventing information leakage. Optimisation is performed using nested cross-validation and macro F1-score is used as the main metric because of class imbalance. Random Forest is selected as the best model, with a mean macro F1-score of 0.2870 in nested cross-validation. The final evaluation is performed using out-of-fold predictions obtained with `cross_val_predict` and the pipeline configured with the modal hyperparameters. This evaluation obtains a macro F1-score OOF of 0.2851 and an accuracy OOF of 0.4818. The final model selects five variables: `volatile_acidity`, `chlorides`, `free_sulfur_dioxide`, `density` and `alcohol`. Finally, the micro-averaged Precision-Recall curve obtains an Average Precision of 0.4897 and an optimal operating point with threshold 0.2511, precision 0.4343, recall 0.7362 and F1-score 0.5463. As a complementary analysis, the micro-averaged ROC curve achieves an AUC of 0.8787.

Keywords: wine quality, multiclass classification, nested cross-validation, Random Forest, feature selection, Precision-Recall curve.

2. Análisis Exploratorio de Datos (EDA)

2.1. Descripción general del conjunto de datos

El conjunto de datos utilizado es wine_quality.csv, formado inicialmente por 6497 observaciones y 12 variables. La variable respuesta es quality, que representa la calidad del vino mediante valores enteros comprendidos entre 3 y 9. El resto de variables son características físico-químicas del vino, como acidez, cloruros, densidad, pH, sulfatos y alcohol.

En la revisión inicial no se detectaron valores perdidos en las variables del conjunto de datos limpio. Sí se identificaron 1179 filas duplicadas, que fueron eliminadas antes de realizar el análisis exploratorio y el modelado posterior. Tras esta limpieza básica, el conjunto quedó formado por 5318 observaciones y 12 variables.

Todas las variables predictoras son numéricas, por lo que no fue necesario codificar variables categóricas. Esta característica simplifica el preprocesado posterior, aunque sigue siendo necesario escalar las variables para modelos sensibles a la escala, como KNN, SVM y regresión logística.

Aspecto	Resultado
Observaciones iniciales	6497
Número de variables	12
Filas duplicadas eliminadas	1179
Observaciones tras limpieza	5318
Valores perdidos tras limpieza	0
Variable respuesta	quality
Tipo de problema	Clasificación multiclase

Tabla 1. Resumen inicial del conjunto de datos.

2.2. Distribución de la variable respuesta

La variable quality presenta una distribución claramente desbalanceada. Las clases más frecuentes son las calidades 5 y 6, mientras que las clases extremas, especialmente 3 y 9, aparecen con una frecuencia muy reducida. Este patrón es importante porque condiciona la evaluación de los modelos: una accuracy elevada podría estar explicada principalmente por aciertos en las clases mayoritarias.

Por este motivo, en la parte de modelado se prioriza F1-macro frente a accuracy. F1-macro calcula el rendimiento por clase y después realiza la media, dando el mismo peso a cada clase independientemente de su frecuencia. De esta forma se obtiene una evaluación más adecuada para un problema multiclase desbalanceado.

Quality	Frecuencia	Porcentaje (%)
3	30	0.56
4	206	3.87
5	1751	32.93
6	2323	43.68
7	855	16.08
8	148	2.78
9	5	0.09

Tabla 2. Distribución de frecuencias de la variable quality.




Figura 1. Distribución de la calidad del vino tras la eliminación de duplicados.

2.3. Análisis descriptivo de las variables predictoras

El análisis descriptivo muestra que las variables se encuentran en escalas muy diferentes. Por ejemplo, `total_sulfur_dioxide` y `free_sulfur_dioxide` presentan valores de magnitud mucho mayor que variables como `density`, `chlorides` o `volatile_acidity`. Esta diferencia de escalas justifica el uso posterior de `StandardScaler` dentro del pipeline de modelado.

Algunas variables presentan distribuciones asimétricas y colas largas, como `residual_sugar`, `chlorides` o `free_sulfur_dioxide`. En cambio, variables como `pH` y `density` se concentran en intervalos relativamente estrechos. Estas diferencias de distribución también explican la conveniencia de comparar varios modelos, ya que no todos responden igual ante asimetrías y posibles valores extremos.

Variable	Media	Desv. típica	Mínimo	Mediana	Máximo
<code>volatile_acidity</code>	0.3442	0.1683	0.0800	0.3000	1.58
<code>chlorides</code>	0.0567	0.0369	0.0090	0.0470	0.6110
<code>free_sulfur_dioxide</code>	30.03	17.80	1.00	28.00	289.00
<code>density</code>	0.9945	0.0030	0.9871	0.9947	1.04
<code>alcohol</code>	10.55	1.19	8.00	10.40	14.90
<code>quality</code>	5.80	0.88	3.00	6.00	9.00

Tabla 3. Estadísticos descriptivos de variables relevantes.

2.4. Valores atípicos

Se revisaron los posibles valores atípicos mediante el criterio del rango intercuartílico. La presencia de outliers es habitual en variables físico-químicas y no implica necesariamente errores de medición. Por ello, en esta fase se identifican y describen, pero no se eliminan automáticamente.

Las variables con mayor proporción de valores atípicos fueron `fixed_acidity`, `volatile_acidity` y `chlorides`. Aun así, los porcentajes se mantienen en niveles moderados, por lo que se decidió conservar las observaciones para no perder información, especialmente teniendo en cuenta el desbalanceo de la variable respuesta.

Variable	N outliers	Porcentaje (%)
fixed_acidity	304	5.72
volatile_acidity	279	5.25
chlorides	237	4.46
sulphates	163	3.07
citric_acid	143	2.69
residual_sugar	141	2.65

Tabla 4. Variables con mayor número de valores atípicos según el criterio IQR.

2.5. Relación entre variables predictoras y quality

La matriz de correlación permite obtener una primera aproximación lineal a la relación entre las variables predictoras y la calidad del vino. La variable con mayor correlación positiva con quality es alcohol, con un coeficiente de 0.469. Esto indica que, en promedio, los vinos con mayor contenido alcohólico tienden a recibir mejores puntuaciones.

Por el contrario, density, volatile_acidity y chlorides presentan correlaciones negativas con quality. En concreto, density muestra una correlación de -0.326, volatile_acidity de -0.265 y chlorides de -0.202. Estas relaciones sugieren que valores elevados de dichas variables se asocian con calidades más bajas, aunque la correlación no debe interpretarse como causalidad.

Variable	Correlación con quality
alcohol	0.469
citric_acid	0.098
free_sulfur_dioxide	0.054
sulphates	0.042
pH	0.040
fixed_acidity	-0.080
chlorides	-0.202
volatile_acidity	-0.265
density	-0.326

Tabla 5. Principales correlaciones con la variable quality.




Figura 2. Matriz de correlación entre las variables numéricas.

2.6. Comparación de variables por niveles de calidad

Además del análisis de correlación, se compararon las distribuciones de las variables predictoras entre los diferentes niveles de quality. Este análisis permite comprobar si las variables presentan diferencias relevantes entre grupos de calidad. En el notebook se emplearon diagramas de caja y la prueba no paramétrica de Kruskal-Wallis.

Los resultados de Kruskal-Wallis muestran diferencias estadísticamente significativas entre niveles de calidad para todas las variables analizadas. Las variables con mayor estadístico fueron alcohol, density, chlorides y volatile_acidity, lo que coincide con las relaciones observadas en la matriz de correlación y con las variables que posteriormente fueron seleccionadas por el procedimiento automático.

Variable	Estadístico Kruskal-Wallis	p-valor
alcohol	1333.407	6.35e-285
density	727.710	6.35e-154
chlorides	534.982	2.44e-112
volatile_acidity	384.019	7.61e-80
free_sulfur_dioxide	113.403	3.95e-22
citric_acid	76.109	2.27e-14

Tabla 6. Variables con mayores diferencias entre niveles de quality según Kruskal-Wallis.

2.7. Conclusiones del EDA para el modelado

El EDA permite extraer varias conclusiones relevantes para el modelado. En primer lugar, el problema debe tratarse como una clasificación multiclase, ya que la variable `quality` toma valores discretos entre 3 y 9. En segundo lugar, la distribución de la respuesta está claramente desbalanceada, con predominio de las clases 5 y 6 y muy pocos ejemplos en las clases extremas. Por ello, la evaluación posterior no debe basarse únicamente en `accuracy`, sino también en métricas que tengan en cuenta todas las clases, como `F1-macro`.

En tercer lugar, las variables predictoras presentan escalas diferentes y algunas distribuciones asimétricas, lo que justifica incluir imputación, escalado y selección de variables dentro del pipeline de aprendizaje. Finalmente, el análisis de correlación y las pruebas de comparación por grupos apuntan a `alcohol`, `density`, `volatile_acidity`, `chlorides` y `free_sulfur_dioxide` como variables especialmente relevantes para predecir la calidad del vino. Estas conclusiones serán contrastadas posteriormente mediante validación cruzada anidada y modelos de machine learning.

3. Modelos Machine Learning utilizados en la predicción

En este apartado se describen las técnicas de Machine Learning utilizadas para predecir la variable respuesta `quality` del conjunto de datos de vinos. Como se trata de una variable discreta con varios valores posibles, el problema se aborda como una tarea de clasificación multiclase. El objetivo de los modelos es aprender, a partir de las variables químicas disponibles, una regla de decisión capaz de asignar a cada vino una clase de calidad. Para ello se han utilizado cuatro enfoques distintos: Regresión Logística, K-Nearest Neighbors, Support Vector Machine con kernel RBF y Random Forest. Esta selección permite comparar modelos lineales, modelos basados en distancias, modelos de margen con kernel y un método ensemble basado en árboles de decisión.

3.1. Planteamiento general de clasificación supervisada

En un problema de aprendizaje supervisado se dispone de un conjunto de observaciones para las que se conocen tanto las variables explicativas como la variable objetivo. En este caso, las variables predictoras son medidas físico-químicas del vino, mientras que la variable objetivo es su calidad. Durante el entrenamiento, los algoritmos buscan patrones que relacionen dichas variables con las clases de calidad observadas. Una vez ajustado el modelo, este se utiliza para predecir la calidad de vinos no empleados durante el entrenamiento.

Al tratarse de una clasificación multiclase, el modelo no decide únicamente entre dos posibles resultados, sino entre varias calidades. Esta característica aumenta la dificultad del problema, especialmente cuando algunas clases tienen pocos ejemplos. Por este motivo, no basta con analizar la `accuracy`, ya que esta métrica puede verse dominada por las clases mayoritarias. En el proceso de selección se utiliza también `F1-macro`, que calcula el `F1` de cada clase y después realiza una media otorgando el mismo peso a todas ellas.

3.2. Preprocesado y selección de variables

Antes de aplicar los modelos, las variables se integran en un pipeline de preprocesado. Aunque el conjunto de datos no presenta valores perdidos, se incluye una imputación mediante la mediana para hacer el procedimiento más robusto. Posteriormente se aplica una estandarización de las variables numéricas. Esta transformación centra las variables y las escala para que tengan una magnitud comparable, lo cual es especialmente importante en métodos basados en distancias o productos escalares, como KNN, SVM y Regresión Logística.

Además, se incorpora una etapa de selección de variables mediante `SelectKBest`. Esta técnica evalúa cada variable de forma univariante en relación con la respuesta y conserva las `k` variables con mayor puntuación. En el trabajo se prueban distintos valores de `k` dentro de la búsqueda de hiperparámetros. La selección se realiza dentro del pipeline y dentro de la validación cruzada, evitando así utilizar información del conjunto de validación o test durante el proceso de selección. Esta precaución es importante para evitar fuga de información y obtener una estimación más realista del rendimiento.

Modelo	Tipo de enfoque	Ventaja principal	Aspecto a controlar
Regresión Logística	Modelo lineal de clasificación	Modelo interpretable y útil como referencia base	Puede ser insuficiente si las fronteras son no lineales
KNN	Clasificador basado en vecinos	No asume una forma paramétrica concreta	Muy sensible a la escala y al valor de k
SVM RBF	Modelo de margen con kernel no lineal	Permite fronteras de decisión complejas	Depende de C, gamma y del coste computacional
Random Forest	Método ensemble de árboles	Captura relaciones no lineales y reduce varianza	Puede ser menos interpretable que modelos simples

Tabla 7. Modelos considerados en el trabajo.

3.3. Regresión Logística

La Regresión Logística es un modelo clásico de clasificación que estima la probabilidad de pertenencia a cada clase a partir de una combinación lineal de las variables predictoras. Aunque su nombre incluye el término regresión, en este contexto se utiliza como clasificador. En problemas multiclase puede extenderse para estimar simultáneamente la probabilidad de cada categoría de la variable respuesta.

Su principal ventaja es la sencillez y la interpretabilidad. Permite disponer de un modelo de referencia con el que comparar técnicas más complejas. Sin embargo, al basarse en relaciones lineales entre las variables y la respuesta, puede tener dificultades si la separación entre clases requiere fronteras de decisión no lineales. En este trabajo se utiliza como modelo base, incorporando regularización mediante el parámetro C y probando también la posibilidad de ponderar las clases para compensar el desbalanceo.

3.4. K-Nearest Neighbors (KNN)

K-Nearest Neighbors es un método no paramétrico basado en la proximidad entre observaciones. Para clasificar un nuevo vino, el algoritmo busca los k ejemplos de entrenamiento más cercanos según una medida de distancia y asigna la clase en función de las clases de esos vecinos. Puede utilizar una votación uniforme, en la que todos los vecinos pesan lo mismo, o una votación ponderada por distancia, en la que los vecinos más cercanos tienen mayor influencia.

Este modelo puede capturar relaciones locales sin imponer una forma funcional concreta. No obstante, es muy sensible a la escala de las variables, ya que las distancias pueden quedar dominadas por aquellas con mayor rango numérico. Por eso se aplica estandarización antes de entrenarlo. También depende de la elección de k: valores pequeños pueden dar modelos muy variables, mientras que valores demasiado grandes pueden suavizar en exceso las fronteras de decisión. En la optimización se prueban diferentes números de vecinos, ponderaciones y métricas de distancia.

3.5. Support Vector Machine con kernel RBF

Support Vector Machine es un algoritmo de clasificación que busca separar las clases mediante una frontera de decisión con el mayor margen posible. En su versión lineal, esta frontera es un hiperplano; sin embargo, mediante funciones kernel puede proyectarse implícitamente la información a espacios de mayor dimensión y construir fronteras no lineales. En este trabajo se utiliza el kernel RBF, adecuado cuando las relaciones entre variables y clases no son necesariamente lineales.

Los parámetros más relevantes son C y gamma. El parámetro C controla el equilibrio entre maximizar el margen y penalizar errores de clasificación. Valores altos pueden ajustar mejor los datos de entrenamiento, pero también aumentar el riesgo de sobreajuste. El parámetro gamma controla el alcance de influencia de cada observación en el kernel RBF: un gamma alto genera fronteras más flexibles y locales, mientras que un valor bajo produce fronteras más suaves. Debido a su sensibilidad a la escala, SVM se entrena después de estandarizar las variables.

3.6. Random Forest como modelo ensemble

Random Forest es un método ensemble basado en la combinación de múltiples árboles de decisión. Cada árbol se entrena sobre una muestra aleatoria de los datos y, en cada división, considera solo un subconjunto de variables. Esta doble aleatoriedad permite reducir la varianza respecto a un único árbol y mejorar la capacidad de generalización. La predicción final se obtiene por votación entre los árboles del bosque.

Este modelo resulta apropiado para datos tabulares, ya que puede capturar relaciones no lineales e interacciones entre variables sin requerir transformaciones explícitas. Además, es menos sensible a la escala que KNN o SVM, aunque en el trabajo se mantiene el mismo esquema de pipeline para comparar todos los modelos de forma homogénea. En la búsqueda de hiperparámetros se ajustan aspectos como el número de árboles, la profundidad máxima, el número mínimo de muestras para dividir nodos y la ponderación de clases. Al ser un método ensemble, cumple también el requisito de incluir al menos una técnica de este tipo en el trabajo.

3.7. Comparación conceptual de los modelos

Los cuatro modelos seleccionados representan enfoques complementarios. La Regresión Logística permite establecer una referencia sencilla e interpretable. KNN aporta una perspectiva local basada en similitud entre vinos. SVM con kernel RBF permite construir fronteras no lineales controladas por parámetros de regularización. Random Forest, por su parte, combina muchos árboles para obtener un clasificador más estable y flexible.

Esta diversidad es útil porque no se conoce de antemano qué estructura presentan los datos. Si las clases pudieran separarse de forma aproximadamente lineal, la Regresión Logística sería suficiente. Si la calidad dependiera de patrones locales, KNN podría ser competitivo. Si las fronteras fueran complejas, SVM o Random Forest podrían ofrecer mejores resultados. Por este motivo, la elección final del modelo no se realiza únicamente con argumentos teóricos, sino mediante un proceso posterior de optimización y validación cruzada anidada.

3.8. Relación con las métricas de evaluación

La comparación de modelos requiere definir una métrica principal. En este trabajo se prioriza F1-macro porque la variable `quality` está desbalanceada. Esta métrica combina precisión y recall para cada clase y después calcula la media no ponderada entre clases. De esta manera, las clases minoritarias influyen en la evaluación y el modelo no se selecciona únicamente por su comportamiento sobre las clases más frecuentes.

La accuracy se conserva como métrica complementaria, ya que permite conocer el porcentaje global de aciertos. Sin embargo, en problemas desbalanceados puede resultar optimista si el modelo acierta principalmente las clases con más observaciones y falla las menos frecuentes. Por ello, la selección definitiva se apoya en F1-macro, mientras que la accuracy, la matriz de confusión y el informe de clasificación se utilizan para interpretar con más detalle el comportamiento del modelo elegido.

Técnica	Papel en el trabajo
Regresión Logística	Modelo lineal base para disponer de una referencia inicial.
KNN	Modelo basado en similitud entre observaciones, útil para patrones locales.
SVM RBF	Modelo no lineal capaz de construir fronteras de decisión complejas.
Random Forest	Modelo ensemble flexible para datos tabulares y relaciones no lineales.
SelectKBest	Selección de variables dentro del pipeline y de la validación cruzada.

Tabla 8. Papel de cada técnica dentro del análisis.

3.9. Hiperparámetros y control de la complejidad

Todos los modelos utilizados dependen de hiperparámetros que no se aprenden directamente durante el ajuste, sino que deben definirse antes del entrenamiento. Estos hiperparámetros controlan la complejidad del modelo y, por tanto, el equilibrio entre sesgo y varianza. Un modelo demasiado simple puede no capturar la estructura de los datos, mientras que un modelo excesivamente flexible puede ajustarse demasiado al conjunto de entrenamiento y perder capacidad de generalización. Por ello, los hiperparámetros se optimizan de forma sistemática dentro de la validación cruzada interna.

En Regresión Logística y SVM, el parámetro C regula la intensidad de la regularización. En KNN, el número de vecinos determina si la predicción se apoya en un entorno muy local o en una vecindad más amplia. En Random Forest, la profundidad de los árboles, el número mínimo de muestras por nodo y el número de árboles controlan la capacidad del bosque para capturar patrones complejos. Además, en varios modelos se considera `class\_weight`, que permite ponderar las clases para reducir el efecto del desbalanceo.

Modelo	Hiperparámetros relevantes	Interpretación
Regresión Logística	C, class_weight	Controlan la regularización y el posible ajuste por desbalanceo de clases.
KNN	n_neighbors, weights, p	Definen el tamaño de la vecindad, la ponderación y la métrica de distancia.
SVM RBF	C, gamma, class_weight	Regulan la penalización de errores, la flexibilidad del kernel y el balanceo de clases.
Random Forest	n_estimators, max_depth, min_samples_split, min_samples_leaf, class_weight	Controlan el tamaño del bosque, la profundidad de los árboles y la complejidad de las particiones.
SelectKBest	k	Determina el número de variables predictoras conservadas antes de ajustar el modelo.

Tabla 9. Hiperparámetros principales considerados de forma teórica.

3.10. Interpretabilidad y adecuación al conjunto de datos

Los modelos también se diferencian por su nivel de interpretabilidad. La Regresión Logística es el más sencillo de explicar, ya que su funcionamiento se basa en una combinación lineal de las variables. KNN resulta intuitivo, porque clasifica por similitud, aunque no proporciona una ecuación global sencilla. SVM con kernel RBF y Random Forest son más flexibles, pero su interpretación directa es menos inmediata. En este trabajo se prioriza el rendimiento predictivo, pero se conserva la interpretación mediante el análisis de variables seleccionadas y la matriz de confusión.

Dado que el conjunto de datos está formado por variables numéricas y tabulares, todos los modelos considerados son adecuados desde el punto de vista técnico. Los modelos basados en escala, como KNN, SVM y Regresión Logística, se benefician del escalado previo. Random Forest no lo necesita de forma estricta, pero puede integrarse en el mismo pipeline para mantener un procedimiento homogéneo. Esta homogeneidad facilita que la comparación entre modelos se centre en su capacidad predictiva y no en diferencias accidentales de preprocesado.

En síntesis, el conjunto de técnicas elegido permite cubrir modelos simples, modelos locales, modelos no lineales y modelos ensemble. Esta variedad proporciona una base sólida para la comparación empírica posterior. La decisión final sobre el mejor modelo no se basa únicamente en las propiedades teóricas, sino en los resultados obtenidos mediante la optimización y evaluación descritas en el siguiente apartado.

4. Optimización y selección del mejor modelo para la predicción de la variable respuesta, junto con la selección de variables

Este apartado describe el procedimiento seguido para optimizar los modelos de clasificación y seleccionar el mejor modelo para predecir la variable respuesta quality. El proceso se planteó con dos objetivos principales: comparar de forma justa distintos algoritmos de Machine Learning y realizar la selección de variables dentro del propio flujo de validación, evitando que la información del conjunto de prueba influyera en el entrenamiento.

El problema se trató como una clasificación multiclase, ya que la variable quality toma valores discretos correspondientes a diferentes niveles de calidad del vino. Debido al claro desbalanceo observado en el EDA, especialmente por la baja presencia de las clases extremas, se utilizó como métrica principal F1-macro. Esta métrica calcula el F1 de cada clase y después realiza la media, dando el mismo peso a todas las clases, por lo que resulta más adecuada que la accuracy para valorar el rendimiento global en este caso.

4.1. Preparación de los datos y estrategia de validación

Antes de aplicar los modelos, el conjunto de datos se dividió en variables predictoras y variable respuesta. Las variables explicativas fueron las características químicas del vino, mientras que la variable objetivo fue quality. La evaluación principal se realizó mediante validación cruzada anidada, evitando reservar un hold-out adicional para la matriz de confusión final. De esta forma, las métricas finales, la matriz de confusión y las curvas se obtienen posteriormente mediante predicciones out-of-fold, de manera coherente con el proceso de validación.

El preprocesado se integró dentro de un Pipeline de scikit-learn. Este pipeline incluyó una imputación mediante la mediana, aunque el conjunto de datos no presentaba valores perdidos, y una estandarización mediante StandardScaler. Mantener estos pasos dentro del pipeline hace que el procedimiento sea más robusto y evita aplicar transformaciones aprendidas con datos que no deberían intervenir en cada fase de validación.

La selección de variables también se incorporó dentro del pipeline mediante SelectKBest con el estadístico `f_classif`. Se probaron distintos valores de `k`, incluyendo subconjuntos reducidos de variables y la opción de conservar todas las variables. Esta decisión es importante porque la selección de variables se calcula únicamente con los datos de entrenamiento de cada fold, evitando fuga de información.

Para comparar los modelos se utilizó validación cruzada anidada. La validación externa se empleó para estimar el rendimiento de cada modelo, mientras que la validación interna se utilizó para ajustar hiperparámetros y seleccionar el número de variables. Concretamente, se usaron 5 folds externos y 3 folds internos, junto con RandomizedSearchCV con 6 combinaciones por modelo y fold externo.

4.2. Modelos comparados y métrica de selección

Se compararon cuatro modelos de clasificación supervisada: Regresión Logística, KNN, Random Forest y SVM con kernel RBF. Random Forest cumple además el requisito de utilizar al menos un método de tipo ensemble. En todos los casos se evaluaron diferentes configuraciones de hiperparámetros y diferentes valores de `k` para la selección de variables.

La métrica principal fue F1-macro. Aunque también se calculó la accuracy, esta se interpretó como métrica complementaria. Esta decisión está justificada por el desbalanceo de quality: un modelo puede obtener una accuracy relativamente alta si acierta muchas observaciones de las clases mayoritarias, aunque su rendimiento en las clases minoritarias sea pobre.

Modelo	F1-macro medio	Desv. F1-macro	Accuracy media	Desv. accuracy
Random Forest	0.2870	0.0152	0.5034	0.0488
SVM RBF	0.2519	0.0191	0.4859	0.0186
KNN	0.2402	0.0084	0.5346	0.0323
Logistic Regression	0.2400	0.0250	0.5058	0.1084

Tabla 10. Resultados medios de la validación cruzada anidada por modelo.

Los resultados muestran que Random Forest obtuvo el mayor F1-macro medio, con un valor de 0.2870. Aunque KNN y Logistic Regression lograron una accuracy media superior, no fueron seleccionados porque su F1-macro fue menor. Esto indica que esos modelos tienden a funcionar mejor sobre las clases mayoritarias, pero no equilibran tan bien el rendimiento entre todas las clases.

La desviación típica del F1-macro de Random Forest fue de 0.0152, lo que sugiere una variabilidad moderada entre folds externos. Además, al calcular intervalos de confianza al 95 % mediante la t de Student, el intervalo de Random Forest fue [0.2681, 0.3058], solapándose parcialmente con los de SVM RBF y Logistic Regression, aunque no con el de KNN. Por tanto, la diferencia entre algunos modelos no debe interpretarse como concluyente en términos estadísticos. Aun así, Random Forest se mantiene como opción principal por obtener el mayor F1-macro medio y una configuración estable.

4.3. Modelo seleccionado y selección de variables

El modelo seleccionado fue Random Forest. En cuatro de los cinco folds externos, el mejor valor de k para SelectKBest fue 5, mientras que en un fold se seleccionó la opción all. Esto indica que el procedimiento de optimización prefirió mayoritariamente trabajar con un subconjunto reducido de variables en lugar de utilizar todas las variables predictoras disponibles.

Las variables volatile_acidity, chlorides, free_sulfur_dioxide, density y alcohol aparecieron seleccionadas en los cinco folds externos. Esta repetición indica que son las variables más estables del procedimiento. Además, el resultado es coherente con el EDA, donde alcohol, density, volatile_acidity y chlorides mostraban relaciones relevantes con quality. Las restantes variables solo aparecen en el fold donde se seleccionó k = all, por lo que no se consideran tan estables.

Variable seleccionada	Frecuencia de selección
volatile_acidity	5 de 5 folds
chlorides	5 de 5 folds
free_sulfur_dioxide	5 de 5 folds
density	5 de 5 folds
alcohol	5 de 5 folds

Tabla 11. Frecuencia de selección de variables en los folds externos.

La interpretación de esta selección debe hacerse teniendo en cuenta que SelectKBest aplica un criterio estadístico univariante. Es decir, mide la relación individual de cada variable con la respuesta, antes de que el modelo Random Forest aprenda patrones conjuntos. Aun así, al incluirse dentro del pipeline y de la validación cruzada, el proceso de selección se realiza de forma metodológicamente correcta.

4.4. Hiperparámetros finales del modelo

Una vez seleccionado Random Forest como mejor modelo, se fijó la configuración final utilizando la moda de los hiperparámetros seleccionados en los folds externos de la Nested CV, en lugar de realizar una nueva búsqueda global independiente. La configuración modal apareció en 4 de los 5 folds externos y fue la siguiente: select__k = 5, model__n_estimators = 300, model__min_samples_split = 5, model__min_samples_leaf = 2, model__max_features = sqrt, model__max_depth = 10 y model__class_weight = balanced.

Estos valores son razonables para el problema. El uso de 300 árboles aporta estabilidad al ensemble; limitar la profundidad máxima a 10 ayuda a controlar la complejidad; y `class_weight = balanced` introduce una compensación frente al desbalanceo de clases. Además, `min_samples_split` y `min_samples_leaf` evitan divisiones excesivamente específicas, reduciendo el riesgo de sobreajuste. El hecho de que esta configuración sea modal refuerza su estabilidad dentro de la validación cruzada anidada.

4.5. Evaluación out-of-fold del modelo seleccionado

Después de seleccionar el modelo y fijar la configuración modal de hiperparámetros, la evaluación final se realizó mediante predicciones out-of-fold. Para ello se utilizó `cross_val_predict` con el mismo `outer_cv` y el pipeline configurado con la moda de hiperparámetros. De esta forma, cada observación fue predicha por un modelo que no había sido entrenado con ella, evitando una evaluación optimista basada en un split hold-out adicional.

El F1-macro obtenido mediante esta evaluación out-of-fold fue 0.2851 y la accuracy fue 0.4818. Estos resultados son coherentes con la validación cruzada anidada. El F1-macro OOF se mantiene muy próximo al F1-macro medio de la Nested CV, lo que indica que no hay una ruptura clara entre el rendimiento estimado durante la validación y la evaluación final out-of-fold. La clasificación en siete niveles de calidad, junto con el fuerte desbalanceo de las clases extremas, hace que el F1-macro sea bajo y penalice especialmente los errores en las clases minoritarias.

Métrica	Resultado
Modelo seleccionado	Random Forest
Métrica de selección	F1-macro
F1-macro Nested CV	0.2870
Accuracy Nested CV	0.5034
F1-macro OOF	0.2851
Accuracy OOF	0.4818
IC95 F1-macro Nested CV	[0.2681, 0.3058]
IC95 accuracy Nested CV	[0.4428, 0.5640]

Tabla 12. Resumen de métricas del modelo seleccionado.

El informe de clasificación out-of-fold muestra que el modelo funciona mejor en las clases centrales. En particular, la clase 5 obtuvo un F1-score de 0.61, la clase 6 obtuvo 0.45 y la clase 7 obtuvo 0.43. En cambio, las clases extremas, como 3 y 9, presentan un rendimiento muy bajo debido a su escasa representación en el conjunto de datos.

Clase quality	Precision	Recall	F1-score	Support
3	0.23	0.10	0.14	30
4	0.22	0.27	0.24	206
5	0.57	0.66	0.61	1751
6	0.56	0.37	0.45	2323
7	0.36	0.55	0.43	855
8	0.12	0.13	0.12	148
9	0.00	0.00	0.00	5

Tabla 13. Informe de clasificación out-of-fold del modelo final.

4.6. Interpretación de la matriz de confusión

La matriz de confusión out-of-fold confirma esta interpretación. La mayor parte de los aciertos se concentra en las clases 5, 6 y 7. También se observan confusiones frecuentes entre clases próximas, por ejemplo entre 5 y 6 o entre 6 y 7. Este comportamiento es esperable, ya que quality tiene una naturaleza ordinal y las diferencias entre calidades consecutivas pueden ser pequeñas.

Real / Pred.	3	4	5	6	7	8	9
3	3	5	13	6	3	0	0
4	5	56	96	34	13	2	0
5	3	121	1147	358	114	8	0
6	2	60	699	865	631	66	0
7	0	10	63	248	472	62	0
8	0	2	6	31	90	19	0
9	0	0	0	1	4	0	0

Tabla 14. Matriz de confusión out-of-fold multiclase del modelo Random Forest.

En la matriz se aprecia que el mayor número de aciertos se concentra en las calidades 5, 6 y 7. Por ejemplo, el modelo acierta 1147 observaciones de la clase 5, 865 de la clase 6 y 472 de la clase 7. Sin embargo, también existen confusiones importantes entre clases vecinas, especialmente de la clase 6 hacia las clases 5 y 7. Esta pauta es razonable porque las categorías de calidad representan niveles próximos y no grupos completamente separados.

Las clases con muy pocos ejemplos, como 3 y 9, siguen siendo difíciles de predecir correctamente. Esta limitación está relacionada con la escasez de muestras disponibles para esas categorías y no implica por sí sola un fallo del procedimiento de validación. En un trabajo futuro podría estudiarse una recodificación ordinal o una agrupación de calidades bajas, medias y altas, aunque en este análisis se ha mantenido la variable original para respetar el planteamiento multiclase del dataset.

En conjunto, Random Forest se seleccionó como mejor modelo porque ofreció el mayor F1-macro medio en la validación cruzada anidada, mantuvo una selección de variables estable y obtuvo resultados out-of-fold coherentes con la validación. La principal limitación no procede del procedimiento de optimización, sino de la dificultad intrínseca del problema: clasificación multiclase, desbalanceo acusado y similitud entre calidades consecutivas.

5. Curva y punto óptimo de funcionamiento

En este apartado se analiza el comportamiento del modelo seleccionado, Random Forest, mediante curvas basadas en las probabilidades estimadas. El objetivo es estudiar cómo cambia el rendimiento al modificar el umbral de decisión y escoger un punto óptimo de funcionamiento con un criterio justificado.

Dado que quality es una variable multiclase, las curvas se calcularon mediante una estrategia one-vs-rest y agregación micro-promediada. Para mantener la coherencia con la evaluación out-of-fold, se utilizaron las probabilidades obtenidas con cross_val_predict y el pipeline configurado con la moda de hiperparámetros.

5.1. Curva Precision-Recall y criterio de selección

La curva Precision-Recall se toma como referencia principal porque el dataset está desbalanceado. Esta curva muestra el compromiso entre precision y recall, por lo que resulta más informativa que la ROC cuando existen clases con frecuencias muy diferentes.




Figura 3. Curva Precision-Recall micro-promediada del modelo Random Forest.

Indicador	Valor
Average Precision micro	0.4897
Umbral óptimo PR	0.2511
Precision	0.4343
Recall	0.7362
F1	0.5463

Tabla 15. Indicadores de la curva Precision-Recall micro-promediada.

El punto óptimo de la curva PR se eligió maximizando el valor F1, ya que esta métrica equilibra precisión y recall. El umbral seleccionado fue 0.2511, con una precisión de 0.4343, un recall de 0.7362 y un F1 de 0.5463. Este punto prioriza una recuperación elevada de casos frente a una precisión más moderada, lo cual es razonable en un problema multiclase y desbalanceado.

5.2. Curva ROC complementaria

Además se calculó la curva ROC micro-promediada como análisis complementario. Esta curva representa la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos, aunque en problemas desbalanceados puede resultar más optimista que la curva Precision-Recall.




Figura 4. Curva ROC micro-promediada del modelo Random Forest.

Indicador	Valor
AUC ROC micro	0.8787
Umbral óptimo ROC	0.1739
TPR	0.8926
FPR	0.2691

Tabla 16. Indicadores de la curva ROC micro-promediada.

La curva ROC obtuvo un AUC micro de 0.8787, lo que indica una buena capacidad global de discriminación al agregar todas las clases. El punto óptimo según el índice de Youden fue 0.1739, con TPR = 0.8926 y FPR = 0.2691. Aun así, la interpretación principal se basa en la curva Precision-Recall, ya que refleja mejor el compromiso entre aciertos y falsos positivos en presencia de desbalanceo.

6. Conclusiones

El objetivo del trabajo ha sido analizar el conjunto de datos Wine Quality y construir un modelo supervisado capaz de predecir la variable quality a partir de las características fisicoquímicas del vino. El análisis exploratorio inicial permitió comprobar que el conjunto de datos contiene variables numéricas, no presenta valores perdidos y muestra una distribución claramente desbalanceada de la variable respuesta, con una concentración notable en las calidades intermedias 5 y 6. Esta característica condicionó la elección de las métricas de evaluación y la interpretación de los resultados.

Durante el EDA se observó que algunas variables tienen una relación más clara con la calidad del vino. En particular, alcohol presentó la mayor correlación positiva con quality, mientras que density, volatile_acidity y chlorides mostraron correlaciones negativas relevantes. Además, se detectaron valores atípicos en varias

variables, lo que resulta habitual en datos reales de naturaleza química. Estos resultados sirvieron para contextualizar el problema y para justificar la necesidad de aplicar modelos capaces de capturar relaciones no necesariamente lineales.

En la fase de modelización se compararon cuatro técnicas de clasificación: Regresión Logística, KNN, SVM con kernel RBF y Random Forest. La comparación se realizó mediante validación cruzada anidada, utilizando F1-macro como métrica principal debido al desbalanceo de clases. Random Forest fue el modelo con mejor rendimiento medio en la validación cruzada anidada, con un F1-macro de 0,2870 y una accuracy de 0,5034. Aunque otros modelos obtuvieron una accuracy superior, se priorizó F1-macro porque permite valorar mejor el comportamiento global en todas las clases, incluidas las minoritarias.

El modelo final Random Forest seleccionó cinco variables: volatile_acidity, chlorides, free_sulfur_dioxide, density y alcohol. Estas variables fueron las más estables en la validación cruzada, ya que aparecieron seleccionadas en los cinco folds externos, y coinciden en gran medida con las relaciones observadas durante el análisis exploratorio. En la evaluación out-of-fold, el modelo obtuvo un F1-macro de 0,2851 y una accuracy de 0,4818, resultados coherentes con la estimación obtenida mediante validación cruzada. La matriz de confusión mostró que el modelo predice mejor las clases centrales, especialmente 5, 6 y 7, mientras que presenta dificultades en las clases extremas, como 3 y 9, debido a su escasa representación.

La curva Precision-Recall micro-promediada obtuvo un Average Precision de 0,4897. El punto óptimo de funcionamiento se fijó maximizando el valor F1, con un umbral de 0,2511, una precisión de 0,4343, un recall de 0,7362 y un F1 de 0,5463. La curva ROC micro-promediada, usada como análisis complementario, alcanzó un AUC de 0,8787. No obstante, la curva Precision-Recall resulta más adecuada en este caso por el desbalanceo de la variable respuesta.

Elemento	Resultado
Modelo seleccionado	Random Forest
Métrica principal	F1-macro
F1-macro Nested CV	0,2870
Accuracy Nested CV	0,5034
F1-macro OOF	0,2851
Accuracy OOF	0,4818
Average Precision micro	0,4897
AUC ROC micro	0,8787

Tabla 17. Resumen de los principales resultados.

En conjunto, los resultados indican que el problema de predicción de la calidad del vino es complejo debido al desbalanceo de clases, la proximidad entre calidades consecutivas y la limitada representación de los valores extremos. A pesar de ello, el flujo de trabajo utilizado permite obtener una comparación robusta entre modelos, seleccionar variables relevantes y justificar el punto de funcionamiento del clasificador. Como posible mejora futura, podría estudiarse una reformulación ordinal o agrupada de la variable quality, así como técnicas específicas para tratar clases minoritarias.

7. Bibliografía

Las referencias se presentan en formato APA 7. Se incluyen fuentes académicas y documentación técnica utilizadas para fundamentar el dataset, las técnicas de aprendizaje supervisado, la validación de modelos, la selección de variables y la evaluación mediante curvas ROC y Precision-Recall.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20, 273–297.
<https://doi.org/10.1007/BF00994018>

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Modeling wine preferences by data mining from physicochemical properties. *Decision Support Systems*, 47(4), 547–553.
<https://doi.org/10.1016/j.dss.2009.05.016>

Davis, J., & Goadrich, M. (2006). The relationship between Precision-Recall and ROC curves. En *Proceedings of the 23rd International Conference on Machine Learning* (pp. 233–240). Association for Computing Machinery. <https://doi.org/10.1145/1143844.1143874>

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.
<https://doi.org/10.1016/j.patrec.2005.10.010>

Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157–1182.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

scikit-learn developers. (2025). Scikit-learn user guide and API reference. <https://scikit-learn.org/stable/>

UCI Machine Learning Repository. (s. f.). Wine Quality [Conjunto de datos]. University of California, Irvine.
<https://archive.ics.uci.edu/dataset/186/wine+quality>

Nota sobre el dataset utilizado

El fichero utilizado en el notebook, wine_quality.csv, corresponde a una versión proporcionada por el profesor en la que se han unido los dos conjuntos originales de Wine Quality disponibles en UCI: vinos blancos y vinos tintos. Por este motivo, la referencia bibliográfica principal del conjunto de datos se mantiene como UCI Machine Learning Repository y el artículo de Cortez et al. (2009), pero la versión concreta analizada es la entregada para la práctica.